


Machine Learning: Alzheimer's Prediction Dataset



Sebastián Arturo Jacome Herrera
Santiago Valdez Bocardo

Proyecto

Objetivo: Evaluar modelos para predecir el diagnóstico de Alzheimer utilizando técnicas de Machine Learning y Deep Learning



Métodos y Modelos Utilizados

Balanceo de clases, selección de características (PCA) y optimización de hiperparámetros (Grid Search).


Modelos utilizados:

- Logistic Regression
- Decision Tree
- Neural Network
- Support Vector Machine

Dataset

Fuente de datos

Alzheimer's Prediction Dataset (Global) con 74,283 registros, Kaggle.



Atributos Clave


- Datos Demográficos (Edad, Género, Nivel Educativo)
- Factores de Estilo de Vida (Actividad Física, Consumo de Alcohol, Calidad del Sueño)
- Factores Médicos (Diabetes, Hipertensión, Colesterol, Depresión)
- Factores Genéticos y Económicos
- Variable Objetivo: Diagnóstico de Alzheimer (1 = Sí, 0 = No)

Objetivo del dataset

Este conjunto de datos es útil para modelos predictivos, estudios epidemiológicos e investigaciones sanitarias sobre la enfermedad de Alzheimer.





Exploración y preprocesamiento




Balanceo de Clases

Distribución de la variable objetivo (58.65% No, 41.35% Sí) no está completamente balanceada




Near Miss (Undersampling)

Se redujo la cantidad de datos de la clase mayoritaria.




SMOTE (Oversampling)

Se generaron nuevas muestras sintéticas de la clase minoritaria.



Random Oversampling

Se generaron nuevas muestras sintéticas de la clase minoritaria de forma aleatoria



Random Undersampling

Se redujo la cantidad de datos de la clase mayoritaria de forma aleatoria.

Modelos Probados

Se entrenaron y evaluaron los siguientes modelos. De ellos, se seleccionaron: Neural Network + SMOTE, SVM + Original, Logistic Regression + SMOTE

DECISION TREE

- Sin balance: 63.04%
- Oversampling: 61.91%
- Near Miss: 60.49%
- SMOTE: 62.87%
- **Undersampling: 72.10%**

LOGISTIC REGRESSION

- Sin balance: 71.11%
- Oversampling: 71.43%
- Near Miss: 69.78%
- SMOTE: 71.11%
- Undersampling: 70.70%

SVM (SUPPORT VECTOR MACHINE)

- Sin balance: 71.74%
- Oversampling: 70.82%
- Near Miss: 69.88%
- SMOTE: 71.58%
- Undersampling: 71.41%


NEURAL NETWORK (RED NEURONAL CON KERAS)

- Sin balance: 71.96%
- **Oversampling: 72.38%**
- Near Miss: 68.70%
- SMOTE: 71.78%
- **Undersampling: 72.37%**

PCA

Se redujo la dimensionalidad para reducir el ruido

Varianza explicada



Resultados

Algoritmo	No. de Features Original	No. de Features Nuevo	Accuracy
Neural Network Oversampling	18	14	61.17%
Neural Network Undersampling	18	14	60.91%
Decision Tree Undersampling	18	14	64.54%

Optimización de Hiperparámetros

La Optimización de Hiperparámetros se hizo sobre el mejor modelo obtenido: "NN Random Over Sampling"

GridSearch Manual

La optimización de hiperparámetros se tuvo que hacer a mano por un error ('__sklearn_tags__ not found') que nos soltaba con el método visto en clase.

Parámetros Evaluados

Se probó el GridSearch con los siguientes

parámetros:

- Optimizer
- Neuronas
- Batch Size
- Epochs

Total de Combinaciones

Por cada uno de los parámetros, se utilizaron dos diferentes variables. Dando así 64 combinaciones en total

Optimización de Hiperparámetros

Tabla de Hiperparámetros

Parámetro	Valores
Optimizer	'adam', 'rmsprop'
Neurona 1	64, 32
Neurona 2	32, 16
Neurona 3	16,8
Batch Size	16, 32
Epochs	5, 10

Resultados

Los mejores parámetros fueron:

Optimizer: adam

Neurons Layer 1: 64

Neurons Layer 2: 32

Neurons Layer 3: 8


Batch Size: 16

Epochs: 5

Con un accuracy del 72.50

Resultados y Comparación de Modelos

El mejor algoritmo fue: **Neural Network**



Accuracy antes del balanceo de clases

71.96%

Accuracy después del balanceo de clases


ROS: 72.38%, RUS: 72.37%, SMOTE:
71.78%, Near Miss: 68.70%

Accuracy después de PCA

61.17%

Accuracy después de GridSearch

72.50%



Conclusiones

Con este proyecto se pudo demostrar la importancia de realizar un pipeline completo de Machine Learning para el entrenamiento de modelos para ciertos proyectos, en este caso para un proyecto sobre Alzheimer. Se realizaron múltiples experimentos con técnicas de balanceo de clases, selección de características y optimización de hiperparámetros, para de esta forma poder construir el mejor modelo posible y obtener los mejores resultados.

1. **Neural Network con OverSampling y optimizando con Grid Search** se encontró el mejor modelo, alcanzando una accuracy superior a todos los demás.
 2. **SVM y Decision Tree no se quedan muy lejos de las Redes Neuronales**, ya que siempre estuvieron cerca en el podio, utilizando tanto SMOTE como el dataset original sin balanceo.
 3. **PCA** impactó negativamente los resultados de los tres mejores modelos y algoritmos.
- 